

گزارش پژوهه پیاده‌سازی مقاله:

Approximation-based Fault Tolerance in Image Processing Applications

Matteo Biasielli, Cristiana Bolchini, Senior Member, IEEE, Luca Cassano, Member,
IEEE, Andrea Mazzeo, Antonio Miele, Senior Member, IEEE

چکیده مقاله مرجع

تحمل خطا^۱ در پردازش تصویر به دو دلیل: ۱) طبیعت افزونگی^۲ در عکس‌ها و ۲) امکان استفاده از خروجی نهایی توسط مصرف‌کننده حتی اگر عکس دارای خطا‌هایی در اطلاعات باشد، کاربرد بالقوه و غیرقابل اغماضی دارد. استفاده از تکنیک کلاسیک DWC^۳ در اینجا خیلی سخت‌گیرانه خواهد بود چرا که اگر دو تصویر کاملاً با هم یکی نباشند آن‌ها را رد می‌کند که این مطابق میل ما نیست.

در این مقاله روشی بهمراه آسان‌گیرانه‌تر از DWC ارائه شده: ۱) در این روش یکی از کپی‌های دقیق جایگزین نمونه تقریبی خواهد شد و ۲) بهجایی استفاده از گروه‌بندی دارای خطا و بدون خطا دودسته بندی قابل استفاده و بلااستفاده ارائه شده که این امر با استفاده از ابزار چک کننده^۴ CNN^۵ پیاده‌سازی شده. برای میزان کردن طرح ارائه شده، متدولوژی^۶ خاصی معرفی شده که هم زمان اجرا و هم قابلیت تشخیص خطا^۷ در سیستم سخت‌افزاری را بهبود می‌بخشد. نتایج ارائه شده برای کاربرد این روشی که مقاله داده به شرح ذیل است: ۱) کاهش متوسط زمان اجرا بالغ بر ۳۰٪ به نسبت روش DWC و ۲) کمتر از ۴٪ اشتباه در قراردادن تصاویر در دسته غیرقابل استفاده‌ها.

¹ Fault tolerance

² Redundancy

³ Duplicant With Comparission

⁴ Convolutional neural network

⁵ Methodology

⁶ Fault detection

(۱) مقدمه

پردازش تصویر به طور وسیعی برای عملکردهای ادراکی چون دستیار کنترل خودمختار در سفینه فضایی و رباط راننده خودمختار و ... ساخته شده و مورد کاربری قرار گرفته اگر مبنا را انجام چنین عملیات بدانیم چنین سیستم‌های محاسباتی باید در دسته سیستم‌هایی اینم برای انجام مأموریت حیاتی با مکانیزمی که تحمل خطا را دارد و سطح مورد انتظار از اطمینان را برآورده می‌کند قرار گیرنده، حتی سیستم‌هایی که امروزه در حال توسعه هستند برای چنین کاربردهایی سخت‌افزارهایی گران‌قیمت اما به طور معمول کنترل را تولید می‌کنند که حتی بیت به بیت خروجی را دوباره و سه باره چک می‌کنند که خطای وجود نداشته باشد، تمامی این سیستم‌هایی که به آن‌ها اشاره شد دارای هزینه بالا، زمان اجرای بالا و توان مصرفی بالا خواهند بود.

برای کاهش هزینه سربار در پیاده‌سازی چنین سیستم‌های سخت‌افزاری باید دو نکته را در نظر بگیریم: ۱) در سیستم‌هایی که پیش‌تر به آن‌ها اشاره کردیم هر دوی کاربردهای حیاتی و غیرحیاتی در کنار هم وجود دارند.

۲) کاربردهایی که مربوط به پردازش تصویر می‌شوند به دلیل ذات منعطفی که پردازش تصویر در برابر خطا دارد می‌توانند تا حدی در برابر خطاها بی‌چشم‌پوشی کنند و سیستم آن‌ها را تحمل کند.

در یک سمت در کاربردهای این‌چنینی ورودی‌های سیستم به صورت مکرر دارای نویز^۷ یا کوانتیزه شدگی^۸ هستند که همین باعث وجود اشکال^۹ در خروجی است، در سمت دیگر کاربری مثل انسان وجود دارد که می‌تواند خروجی را حتی با وجود تغییر جزئی و یا نویز استفاده کند، وجود چنین طبیعت منعطف در برابر خطاها که اشاره شد در دهه گذشته به صورت گسترده‌ای مورداستفاده قرار گرفته تا بین کارایی سیستم و انرژی که سیستم مصرف می‌کند و کیفیتی که خروجی آن دارد یک هماهنگی و تعادلی وجود داشته باشد.

در چند سال اخیر ذات تحمل پذیری در برابر خطا که سیستم‌های پردازش تصویر دارند مورد کاربرد قرار گرفته تا روش نوینی برای کشف خطا به وجود بیاید، این شیوه نوین سعی دارد تا تمرکز را روی سیستمی که خروجی‌های آن در دودسته قابل استفاده و غیرقابل استفاده است و قابلیت این را دارد که حدس بزند خروجی قابل استفاده برای کارهای سیستم هست یا خیر قرار دهد که این کلاس‌بندی را CNN انجام می‌دهد، پیاده‌سازی سخت‌افزاری بر اساس این است که تشخیص دهد خروجی با وجود خطاها بی‌چشم‌پوشی که دارد آیا می‌تواند انتظارات ما برآورده سازد و اینکه روی خروجی نهایی سیستم این خطاها تأثیری دارد یا خیر همچنین سخت‌افزاری که پیاده شده پایپ لاین^{۱۰} های گذشته را به بلوک‌های کنترلی^{۱۱} تبدیل کرده که به صورت تقریبی کار چک‌کردن

⁷ Noise

⁸ Quantized

⁹ Error

¹⁰ Pipeline

¹¹ Control blocks

را برای هر بلاک انجام می‌دهد، پروپوزالی که معرفی شد شیوه‌ای را ارائه می‌کند که زمان بهبود^{۱۲} کمتری دارد؛ اما هزینه سربار آن به اندازه شیوه DWC هست.

۲) مدل سیستم

مدل طراحی شده این مقاله بهبود یافته مدل DWC است، مدل اصلی خود یک کنترل تحمل‌پذیر اشکال برای سیستم‌های پردازش تصویر است، اما در این مدل حتی بیت‌ها هم باید با هم برابر باشد و خروجی باید بدون هیچ‌گونه اشکال یا نویزی باشد، اما این مقاله با استفاده از دو رویکرد: ۱) استفاده از CNN برای دسته‌بندی عکس‌ها در دو گروه قابل استفاده و غیرقابل استفاده (که البته مانند CWP سربار ۲ برابری دارد؛ ولی به طرز شگفت‌آوری زمان اجرای سخت‌افزاری کاهش می‌یابد) و ۲) پیاده‌سازی سخت‌افزاری که دارای بلوک‌های کنترلی شامل کنترل‌کننده‌های هوشمند^{۱۳}((SCs)) است که با هر کدام از پایپ لاین‌هایی که تشکیل شده از فیلتر برای پردازش تصویر جفت شده و به طور تقریبی تصویر ورودی را چک می‌کند.

شکل ۱ شمای کلی از مدل ارائه شده توسط مقاله را نشان می‌دهد، در این شکل عکس ورودی به خط لوله شبکه عصبی (CNN) تحت عنوان input_image وارد شبکه عصبی می‌شود تا از لایه‌های مختلف عبور کند و در نهایت خروجی شبکه عصبی تحت عنوان output_image، طبق الگوریتم کلاس‌بندی^{۱۴} که شبکه عصبی از قبل برای آن آموزش دیده عکس خروجی را در یکی از کلاس‌هایی که برای آن تعریف شده قرار دهد، اما موازی با هر لایه در CNN یک بلوک کنترلی (cb) قرار گرفته که در ادامه کارکرد آن را توضیح خواهیم داد:

۲.۱. نحوه کارکرد بلوک کنترلی:

شکل ۲ شمای کلی از یک بلوک کنترلی را نشان می‌دهد، هر بلوک کنترلی از یک ماثول ورودی کوچک، دو کپی از فیلتر (f_i) استفاده شده در لایه موازی با آن که به صورت موازی کار می‌کنند به نام‌های f_i^h، یک TRC و SC تشکیل شده است. در حالت کلی کارکرد یک cb شامل مراحل زیر است :

- ۱) یک ورودی به نام in_img را دریافت می‌کند که دقیقاً همان ورودی لایه موازی با آن است، ورودی دیگر آن out_img است که خروجی f_i لایه متناظر با آن است و ورودی سوم آن هم همان عکس اصلی و ورودی خام اولیه شبکه CNN است .
- ۲) ورودی in_img با یک فاکتور کاهش مقیاس^{۱۵} di کوچک می‌شود (برای هر دو بعد تصویر اعمال می‌شود)

¹² Recovery time

¹³ Smart Checkers

¹⁴ Classification

¹⁵ Downscaling factor

۳) سپس دو فیلتر تکرار شده f_i^{\wedge} به صورت موازی روی تصویر کوچک شده اجرا می‌شوند. اجرا بر روی تصاویر کوچک شده، تکنیک محاسباتی تقریبی در سطح کاربرد^{۱۶} را شامل می‌شود که توسط طرح پیشنهادی برای دستیابی به تحمل خطای سبک وزن^{۱۷} مورد استفاده قرار می‌گیرد.

۴) شروع اجرای TRC روی تصاویر خروجی دو فیلتر تکرار شده، یعنی $ctrl_img$ و 2 ، به این معنا که دو عکس به صورت بیت به بیت با هم مقایسه می‌شوند و خروجی به صورت ok/fail است، اگر خروجی ok باشد؛ یعنی هر دو عکس با فیلترهای تقریبی به صورت سالم هستند و مرحله بعدی یعنی sc که در cb گرفته شروع به کار می‌کند، اگر خروجی به صورت fail باشد؛ یعنی یکی از فیلترهای تقریبی fault خورده و لایه متناظر موازی با آن مجدداً اجرا می‌شود.

۵) این مرحله در صورتی که خروجی در مرحله قبل ok باشد اجرا می‌شود ، sc جزء اصلی طرح تحمل خطا پیشنهادی است که مغز سیستم را تشکیل می‌دهد و مسئول تصمیم‌گیری در مورد حذف تصاویر و اجرای مجدد (D) یا نه (D/) است. همان‌طور که قبلاً بحث شد، یک SC برای هر CB نمونه‌سازی می‌شود. هر sc سه ورودی زیر را می‌گیرد:

(i) تصویر خروجی فیلتر اصلی (fi) به نام out_img

(ii) تصویر خروجی تولید شده توسط یکی از دو f_i^{\wedge} ، $(ctrl_img)$ را دریافت می‌کند ،

(iii) تصویر ورودی خط لوله (in_img) و

(iv) پیام ok/fail تولید شده توسط TRC در مرحله قبل.


بر اساس سه تصویر ورودی که SC با آن تغذیه می‌شود ، SC تصمیم می‌گیرد که آیا imgi را کنار بگذارد و مرحله یکم خط لوله را مجدداً اجرا کند یا خیر.

از آنجایی که $ctrl_imgi$ و out_imgi نیز در اجرای بدون خطا یکسان نیستند، SC باید بین تفاوت‌های ناشی از تقریب و تفاوت‌های ناشی از وقوع خطا (در بالای تقریب) تمایز قائل شود. علاوه بر این، هنگامی که وضعیت دوم رخ می‌دهد، SC باید تأثیر آن را بر خروجی نهایی پیش‌بینی کند، به‌گونه‌ای که تصمیم بگیرد عکس مذکور قابل استفاده هست یا نه و در این حالت خروجی مرحله یکم خط لوله کنار گذاشته شده و یک فیلتر مجدداً اجرا می‌شود. برای انجام این کار، هر SC از یک CNN بهره‌برداری می‌کند که قابلیت استفاده پیش‌بینی شده (U) یا نه (U/) را اعلام می‌کند. به طور خلاصه، هنگامی که سیگنال ok/fail در مرحله ۴ خطای باشد، خروجی SC به


¹⁶ Application-level approximate computing technique

¹⁷ Lightweight fault tolerance

طور خودکار روی D/D تنظیم می‌شود: در این سناریو در واقع یک خطا در یکی از دو فیلتر عکس‌های تقریبی رخداده است.




شکل ۱: یک شماتیکی از طرح تحمل خطا پیشنهادی مقاله.



شکل ۲: ساختار داخلی cb متناظر با لایه i از خط لوله شبکه عصبی

همان‌طور که در شکل ۳ می‌بینید، تصاویر in_img_i و $ctrl_img_i$ قبل از ارسال به CNN کوچک می‌شوند. در واقع in_img_i و $ctrl_img_i$ بزرگ‌تر از $ctrl_img$ هستند، در حالی که ورودی CNN طراحی شده باید یک ماتریس

سه بعدی باشد، جایی که سه تصویر روی هم چیده می شوند؛ بنابراین، in_img_i و $ctrl_img_i$ برای مطابقت با اندازه $ctrl_img_i$ کوچک می شوند. علاوه بر این، تصاویر in_img_i و $ctrl_img_i$ را می توان به طور معقولی کاهش داد تا زمان اجرای CNN را کاهش دهد و در عین حال دقت دسته بندی آن را حفظ کند. بنابراین، in_img_i و $ctrl_img_i$ را می توان با ضریب $dcnn_i$ تغییر اندازه داد، و $ctrl_img_i$ را با ضریب $dcnn_i$ کاهش مقیاس داد، بنابراین سه تصویر کوچکتر با همان اندازه به دست می آیند که باید روی هم چیده شوند. در نهایت، اگر $ctrl_img_i$ و in_img_i ¹⁸ یا نقشه های حرارتی¹⁹ (به جای تصاویر) با مقادیری در محدوده متفاوت از شدت رنگ پیکسل های تصویر ورودی باشند، تصویر ورودی نرمال می شود. این یک گام ضروری برای ایجاد ورودی های یکنواخت تر و سهولت آموزش CNN و همچنین افزایش قابلیت پیش بینی مدل است. خروجی CNN یک مقدار احتمال $ucnn$ است که قابلیت استفاده خروجی نهایی برنامه را تخمین می زند. این مقدار در نهایت با یک آستانه U_{th} مقایسه می شود و طبقه بندی نهایی U یا U/D را ایجاد می کند.



شکل ۳: ساختار داخلی SC متناظر با لایه i از خط لوله شبکه عصبی

¹⁸ Feature maps

¹⁹ Heat maps

۳) ایرادات مدل

۱. این شیوه برای تشخیص خطا کاملاً وابسته به شبکه عصبی که استفاده می‌کند هست در صورتی که اگر خود شبکه (مثل وزن‌ها فیلترهایی که استفاده می‌شود) در هنگام اجرا (و نه در هنگام training) دچار خطا شود (مثلاً²⁰ SEU بخورد)، تشخیص قابل استفاده بودن به مشکل خواهد خورد.

۲. همان‌طور که در خود مقاله هم اشاره شده این شیوه نمی‌تواند برای کارهای حیاطی پیاده‌سازی شود چرا که با اینکه زمان اجرا را تا حد خوبی کاهش داده؛ ولی منفی‌های اشتباه (false negatives) آن در حدود کمتر از ۴٪ است (که این تا حد زیادی به آستانه‌ای CNN به نام U_{th} بستگی دارد) که در مقایسه با DWC (با صفر درصد false negative) که سربار یکسانی با این شیوه دارد یک ایراد محسوب می‌شود.

۳. این شیوه تنها روی دو مطالعه موردی بررسی شده در صورتی که می‌توانست روی پایگاه‌داده‌های مختلف با انواع موضوعات برای پردازش تصویر بررسی شده و خروجی را مورد ارزیابی قرار گیرد تا بتواند بر اساس استدلال قوی‌تری ادعای خود که مبنی بر کاربردی بودن این شیوه است را اثبات کند.


۴) روند پیاده‌سازی

در ابتداء توضیحی در مورد مکانیزم کلی سیستم معرفی شده در مقاله و نقشه کلی پیاده‌سازی آن توسط نویسنده این گزارش می‌پردازیم سپس به صورت جزئی تمامی مراحل پیاده‌سازی را به طور مفصل شرح می‌دهیم.

۴.۱. مکانیزم کلی سیستم:

همان‌طور که در بخش مدل سیستم هم توضیح داده شد یک خط لوله شبکه عصبی داریم که تصاویر را به صورت ورودی می‌گیرد و در نهایت تصمیم می‌گیرد که هر تصویر به چه کلاسی تعلق دارد، شبکه عصبی که نویسنده گزارش برای پیاده‌سازی انتخاب کرده Lenet-5 است که ساختار لایه‌های آن در شکل ۴ نشان‌داده شده:

²⁰ Single Event Upset



شکل ۴ : دیاگرامی از ساختار شبکه عصبی lenet-5

دلیل انتخاب شبکه lenet-5 وجود لایه‌های متعدد convolution و pooling و لایه fully connected است که بیشترین تطابق را با شبکه عصبی که خود مقاله استفاده کرده (شبکه عصبی مورداستفاده مقاله نامی ندارد، صرفاً در مقاله گفته شده که از تعدادی لایه convolution و pooling و لایه fully connected در پیاده‌سازی استفاده شده)، دارد. لازم به ذکر است از هر شبکه عصبی که برای کلاس‌بندی می‌توان از آن استفاده کرد، می‌توانیم استفاده کنیم و همین نقطه قوت مقاله است که پیاده‌سازی را به یک شبکه عصبی خاص محدود نمی‌کند.

در شبکه عصبی ما (lenet-5) موازی با هر لایه دارای فیلتر (convolution و pooling) یک CB قرار می‌گیرد، در پیاده‌سازی که نویسنده این گزارش کرده، برای اینکه کار در مقیاس پایین انجام شود و از ایجاد پیچیدگی بی‌مورد جلوگیری شود، CB برای لایه Convolution اول موازی با این لایه قرار گرفته و بعد از اجرای این لایه بلافاصله اجرا می‌شود تا متوجه شود که عکسی که خروجی لایه اول است سالم مانده باشد و برای لایه‌های بعدی قابل استفاده باشد و خروجی نهایی آن قابل تشخیص و درست باشد، بنابراین مهم‌ترین بخش پیاده‌سازی مربوط به پیاده‌سازی یک CB دقیق است که با بهینه‌ترین دسته‌بندی عکس‌ها در دو دسته قابل استفاده و غیرقابل استفاده، کمترین سربار را به نسبت سیستمی با پیاده‌سازی TMR یا DWC یا Uth داشته باشد و درست‌ترین نتیجه را بگیرد، برای پیاده‌سازی یک CB دقیق باید دو پارامتر Uth و d را که در ادامه در مورد آن توضیح خواهیم داد را به درستی انتخاب کنیم، برای همین شبکه‌ای که در CB قرار گرفته باید با Uth و d های مختلف آموزش داده شود تا شبکه‌ای که بهترین ترکیب Uth و d را دارد برای مدل مذکور انتخاب کنیم.

۴.۲. تعریف حد آستانه U^{۲۱}:

حد آستانه U یا به اختصار U_{th} یک عدد بین ۰ و ۱ است که به وسیله آن قابل استفاده بودن یا نبودن یک عکس توسط شبکه عصبی داخل CB تعریف می شود به این صورت که اگر عکسی که فیلتر تقریبی روی آن خورده (ctrl_img) را به صورت بیت به بیت با عکسی که فیلتر اصلی رو آن خورده (out_img) مقایسه کنیم و تعداد پیکسل هایی که اختلاف آنها از یک حد آستانه (که مقاله ۲ آن را ۰.۰۵ فرض کرده) بیشتر است، بشماریم و نسبت این تعداد پیکسل ها به کل پیکسل های یک عکس از $U_{th} - 1$ بیشتر باشد آن عکس جزو دسته غیرقابل استفاده قرار می گیرد، در واقع U_{th} ممکن است به عنوان درجه اطمینان از قابلیت استفاده ورودی های CNN برای طبقه بندی تصویر به عنوان قابل استفاده نیاز دارد، تفسیر شود. به طور شهودی، هرچه U_{th} بزرگتر باشد، تصاویری که توسط CNN پذیرفته می شوند کمتر است. این به نوبه خود، پتانسیل کاهش مقدار منفی های کاذب را دارد (تصاویر خراب غیرقابل استفاده که به اشتباه پذیرفته شده اند) اما مقدار مثبت کاذب را افزایش می دهد (تصاویر خراب قابل استفاده یا حتی تصاویر خراب نشده که CNN را به اجرای مجدد غیر ضروری سوق می دهد). با توجه به فضای راه حل ما CNN را با بهترین تعادل بین درصد منفی های اشتباه و صرفه جویی در زمان انتخاب می کنیم.

۴.۳. تعریف تقسیم کننده (d)^{۲۲}:

میزان کوچک شدن تصویر در بخش تغییر اندازه^{۲۳} در CB به این پارامتر بستگی دارد، در واقع این پارامتر میزان کوچک شدن تصاویر را هم در بخش اعمال فیلتر تقریبی (di) و هم در بخش تغییر سایز عکس در شبکه عصبی متعلق به (dcnn) CB تعیین می کند، در واقع یکی از نکات مهم پیاده سازی مدل پیشنهادی مقاله انتخاب تکنیک های محاسبات تقریبی^{۲۴} (AC) مناسب برای تولید فیلتر های تقریبی f_i^* برای فیلتر f_i است. طراح کسی است که انتخاب را بر اساس تخصص و دانش در کل برنامه انجام می دهد. اگرچه روش شناسی کلی است و می توان از AC های مختلف استفاده کرد، اما برای سادگی در این کار، تکنیک کاهش مقیاس^{۲۵} را اتخاذ می کنیم. در این زمینه، طراح مجموعه ای از مقادیر مناسب را برای ضریب کاهش مقیاس di انتخاب می کند، که ۱ کران پایین است، که با تقریب / کاهش مقیاس مطابقت ندارد. کران بالایی i_{max} با آموزش شبکه عصبی درون CB مشخص می شود که یک فضای محاسباتی را بوجود می آورد که جلو تر در مورد آن توضیح خواهیم داد. به طور دقیق تر، برای شناسایی چنین کران بالایی، به طور مکرر ضریب مقیاس سازی ورودی های CNN را افزایش می دهیم، تا زمانی که دقت طبقه بندی به دست آمده نسبت به قبل از تغییر روند بالا و پایدار باشد. هنگامی که

²¹ U threshold

²² Devisor

²³ Resize

²⁴ Approximate computing

²⁵ Downscaling

i d_{max} مشخص شد، مقادیر در $[1; i]$ بازه با انتخاب همه متساوی ممکن اندازه‌های تصویر ورودی گنجانده می‌شود.

همان‌طور که گفتیم بعد از مقایسه دو عکس cntr_img1 و cntr_img2 که خروجی فیلترهای تقریبی هستند اگر نتیجه مقایسه OK باشد شبکه عصبی پیاده شده داخل CB تصمیم می‌گیرد که عکس out_img که همان خروجی فیلتر اصلی است آیا قابل استفاده است یا خیر، این مقاله برای پیاده‌سازی شبکه عصبی خود از ابزاری به نام oracle استفاده کرده که کارکرد آن را به طور مفصل در ادامه توضیح خواهیم داد؛ اما با توجه به اینکه ما برای پیاده‌سازی به این ابزار دسترسی نداشتمیم از یک تکنیک دیگر استفاده کردیم که درواقع سعی کرده ایده اصلی oracle را پیاده کند و عملکردی مبتنی بر منطق ابزار oracle داشته باشد تا نتایج به دست آمده از آن درست باشد.

۴.۴. ابزار oracle

یک برنامه کاربر نهایی^{۲۶} ساده برای تقسیم‌بندی که عکس (احتمالاً معیوب) of و عکس همتای مربوطه og را می‌گیرد و در صورتی که فاصله منتهن (یا L1-norm) دو بردار خروجی $\|og - of\|$ کمتر از آستانه ۰.۰۵ باشد یک برچسب U (قابل استفاده) را به عکس ورودی نسبت می‌دهد و در غیر این صورت (فاصله منتهن^{۲۷} از ۰.۰۵) بیشتر باشد برچسب /U (غیرقابل استفاده) را برمی‌گردد.

به طور مثال در پیاده‌سازی تشخیص ساختمان در عکس‌های هوایی توسط مقاله برنامه مورد استفاده توسط مقاله (oracle) ساختمان‌ها را در تصاویر هوایی شناسایی می‌کند. این برنامه یک bitmap را می‌پذیرد و یک نقشه حرارتی با همان اندازه تولید می‌کند که در آن هر پیکسل ورودی در تصویر ورودی با احتمال تعلق پیکسل به یک ساختمان کدگذاری می‌شود. سپس جعبه‌های مرزی^{۲۸} بر روی نقشه حرارتی ترسیم می‌شوند تا ساختمان‌های شناسایی شده برجسته شوند. برنامه کاربردی از چهار مرحله تشکیل شده است:

(i) تیزکردن^{۲۹} (S) یک پیچیدگی که یک هسته^{۳۰} تیز کننده را اعمال می‌کند. این مرحله یک تصویر می‌گیرد و تصویر واضح شده مربوطه را تولید می‌کند.

²⁶ End user

²⁷ Manhattan

²⁸ Boundin -boxes

²⁹ Sharpening

³⁰ Kernel

(ii) آستانه‌گذاری (T) یک طبقه‌بندی پیکسلی را با انجام یک مقایسه کانالی مقادیر^{۳۱} انجام می‌دهد.

iii resharping&convolution یک طبقه‌بندی را بر اساس تغییر شکل تصویر و سپس یک کانولوشن انجام می‌دهد. دو مرحله ذکر شده، تصویر شارپ شده را می‌گیرند و دو ماتریس از مقادیر احتمال را تولید می‌کنند. iv) تجمع (A) یک ضرب پیکسلی بین خروجی‌های دو مرحله قبلی را انجام می‌دهد تا طبقه‌بندی‌های آنها را جمع کند. این مرحله دو ماتریس می‌گیرد و نقشه حرارتی خروجی را تولید می‌کند. به عنوان یک برنامه کاربر نهایی ساده برای شناسایی ساختمان، این مقاله oracle را پیاده‌سازی کرده که یک نقشه حرارتی (احتمالاً معیوب) داده می‌شود و اگر جعبه‌های مرزی در دو نقشه حرارتی حداقل برای ۸۵ درصد با هم همپوشانی داشته باشند، یک برچسب قابل استفاده تولید می‌کند.

تکنیکی که ما جایگزین ابزار oracle کردیم دقیقاً از منطق همین ابزار پیروی می‌کند؛ یعنی قرار است همان دو ورودی $ctrl_img$ و out_img که به oracle می‌دادیم را با تکنیکی مشابه ابزار oracle مقایسه کنیم و اگر دو تصویر $ctrl_img$ و out_img بماندازه Uth یا بیشتر با هم مطابقت داشتند عکس out_img برچسب قابل استفاده بگیرد، برای مقایسه $ctrl_img$ و out_img ما بیت به بیت این دو عکس را با هم مقایسه می‌کنیم اگر در هر دو پیکسل متناظر قدر مطلق اختلاف دو پیکسل از ۰.۰۵ بیشتر باشد یک واحد به شمارندهای که در نظر گرفتیم اضافه می‌کنیم، در نهایت اگر نسبت مقدار شمارنده به تعداد کل پیکسل‌ها از Uth بیشتر باشد یعنی out_img قابل استفاده است و برچسب U به آن تعلق می‌گیرد.

۴.۵ آموزش SC :

برای اینکه بهترین مقدار را برای Uth و d تعیین کنیم لازم است تا شبکه عصبی SC را با راه آموزش دهیم تا بهترین انتخاب را داشته باشیم، معیارهایی که مشخص می‌کند مقدار تنظیم شده برای Uth و d مناسب بوده یکی زمان اجرا و دیگری i) درصد تصاویر غیرقابل استفاده که به اشتباه توسط SC پذیرفته شده است (منفی‌های نادرست)، ii) میانگین زمان اجرای برنامه محافظت شده. اولی از نقطه‌نظر قابلیت اطمینان بسیار مهم است، در حالی که دومی مزایای راه حل را اندازه‌گیری می‌کند. در پیاده‌سازی که نویسنده این گزارش انجام داده ۲ مقدار مختلف برای Uth و دو مقدار مختلف برای d در نظر گرفته و حالت‌های مختلف انتخاب Uth و d با هم که ۴ حالت می‌شود را در نظر گرفته و در نتیجه الگوریتم پیشنهادی برنامه را ۴ مرتبه به‌ازای همه ترکیب‌های Uth و d اجرا کرده و در نهایت با توجه به اینکه معیار اولی توسط مقاله مهم‌تر شمرده شده (دستیابی به کمترین میزان D/U یکی از ۴ حالت را که کمترین منفی نادرست) (D/U) را نسب به بقیه داشته به عنوان بهترین ترکیب d انتخاب می‌کند.

³¹ Channel -wise comparison

به طور کلی برای ارزیابی SC پیاده‌سازی شده عکس‌ها در ۴ دسته‌بندی زیر قرار می‌گیرند:

- ۱) D/U : آنهایی که توسط SC رد نشدند (نیاز به اجرای مجدد لایه متناظر نیست) ولی قابل استفاده نبودند (یک انسان یا ابزار oracle مورد استفاده مقاله نمی‌تواند عکس را با وجود نویزها کلاس‌بندی کند)
- ۲) D/U : آنهایی که SC غیرقابل استفاده تشخیص داده و در واقع هم غیرقابل استفاده بوده‌اند.
- ۳) DU : آنهایی که SC قابل استفاده تشخیص داده و در واقع هم قابل استفاده بوده‌اند.
- ۴) DU : آنهایی که SC غیرقابل استفاده تشخیص داده؛ ولی در واقع قابل استفاده بوده‌اند.

۴.۶. پیاده‌سازی کد سیستم به همراه جزئیات مدل:

در این بخش در مورد کدی که پیاده‌سازی کردہ‌ایم توضیح خواهیم داد و به سایر جزئیات پیاده‌سازی مقاله که پیش‌تر به آن اشاره نکردہ‌ایم در خلال مطالب خواهیم پرداخت.

پایگاه‌داده‌ای که برای پیاده‌سازی استفاده کردہ‌ایم mnist است، پایگاه‌داده mnist یک پایگاه‌داده بزرگ از ارقام دست‌نویس است که معمولاً برای آموزش سیستم‌های مختلف پردازش تصویر استفاده می‌شود.

با استفاده از کد زیر داده‌های آموزش^{۳۲} و برچسب‌های آن‌ها را از پایگاه‌داده mnist می‌گیریم و به ترتیب درون متغیرهای train_x و train_y و همچنین داده‌های آزمایش^{۳۳} و برچسب‌های آن‌ها را از پایگاه‌داده mnist می‌گیریم و به ترتیب درون متغیرهای test_x و test_y می‌ریزیم.

```
from keras.datasets import mnist  
(train_X, train_y), (test_X, test_y) = mnist.load_data()
```

سپس برچسب‌های عکس‌های پایگاه داده را با صدا زدن تابع convertToOneHot به صورت one hot در می‌آوریم :

```
train_labs = convertToOneHot(train_labs)
```

معرفی تابع convertToOneHot : این تابع آرایه یک بعدی از برچسب‌ها را می‌گیرد و یک آرایه دو بعدی با مقادیر صفر به نام oneHotLabels ایجاد می‌کند ، سپس به ترتیب از خانه صفرم این آرایه به خانه متناظر با مقدار برچسب، مقدار ۱ را اختصاص می‌دهد:

```
def convertToOneHot(labels):
```

³² Train

³³ Test

```

oneHotLabels = np.zeros((labels.size, labels.max() + 1))

oneHotLabels[np.arange(labels.size), labels] = 1

return oneHotLabels

```

حال کلاس Lenet را با نرخ یادگیری^{۳۴} دلخواه (۰.۰۱) صدا می‌زنیم و آن را درون متغیر my_CNN می‌ریزیم:

```
my_CNN = LeNet(lr)
```

معرفی کلاس Lenet : این کلاس شامل ۶ تابع است که به ترتیب آن‌ها را معرفی می‌کنیم:

تابع `__init__` : برای مقدار دهی به متغیرها از آن استفاده می‌شود، در بخشی از این کلاس برای مقدار دهی لایه‌های conv و fc از تابع `xavier_init` استفاده شده که در ادامه در مورد آن توضیح خواهیم داد:

```
class LeNet(object):
```

```
#The network is like:
```

```
# conv1 -> pool1 -> conv2 -> pool2 -> fc1 -> relu -> fc2 -> relu -> softmax
```

```
# 10    11    12    13    14    15    16    17    18    19
```

```
def __init__(self, lr=0.1):
```

```
    self.lr = lr
```

```
# 6 convolution kernal, each has 1 * 5 * 5 size
```

```
    self.conv1 = xavier_init(6, 1, 5, 5)
```

```
# the size for mean pool is 2 * 2, stride = 2
```

```
    self.pool1 = [2, 2]
```

```
# 16 convolution kernal, each has 6 * 5 * 5 size
```

```
    self.conv2 = xavier_init(16, 6, 5, 5)
```

```
# the size for mean pool is 2 * 2, stride = 2
```

```
    self.pool2 = [2, 2]
```

```
# fully connected layer 256 -> 200
```

^{۳۴} Learning rate

```

self.fc1 = xavier_init(256, 200, fc=True)

# fully connected layer 200 -> 10

self.fc2 = xavier_init(200, 10, fc=True)

```

تابع forward propagation که داده اولیه (input_data) را می‌گیرد و به ترتیب در لایه‌ها به سمت جلو آن را حرکت می‌دهد، به طور مثال self.l1 لایه convolution است که ورودی آن همان self.l0 (خروجی لایه صفر) است و پارامترهای مورد استفاده در convolution آن در تابع `__init__` تحت عنوان self.conv1 مقدار دهی شده:

```

def forward_prop(self, input_data):

    self.l0 = np.expand_dims(input_data, axis=1) / 255 # (batch_sz, 1, 28, 28)

    self.l1 = self.convolution(self.l0, self.conv1) # (batch_sz, 6, 24, 24)

    self.l2 = self.mean_pool(self.l1, self.pool1) # (batch_sz, 6, 12, 12)

    self.l3 = self.convolution(self.l2, self.conv2) # (batch_sz, 16, 8, 8)

    self.l4 = self.mean_pool(self.l3, self.pool2) # (batch_sz, 16, 4, 4)

    self.l5 = self.fully_connect(self.l4, self.fc1) # (batch_sz, 200)

    self.l6 = self.relu(self.l5) # (batch_sz, 200)

    self.l7 = self.fully_connect(self.l6, self.fc2) # (batch_sz, 10)

    self.l8 = self.relu(self.l7) # (batch_sz, 10)

    self.l9 = self.softmax(self.l8) # (batch_sz, 10)

    return self.l9

```

تابع backward_prop که در مسیر لایه‌ها را از انتهای آغاز حرکت می‌کند و عمل backpropagation را روی CNN انجام می‌دهد برای اینکه وزن‌ها را بروز رسانی کند، همانطور که در کد زیر می‌بینید پارامتر deriv که به تابعهای (مثلًا self.relu) پاس داده می‌شود مقدار true دارد ، این به این معناست که تابع مورد نظر زمانی که صدای می‌شود با چک کردن مقدار deriv بتواند متوجه شود که باید عملیات مربوط به back propagation را

انجام دهد یا forward propagation ، توضیحات بیشتر در مورد جزئیات اتفاقاتی که در زمان backpropagation در هر لایه می‌افتد در زمانی که در مورد توابع مورد نظر صحبت می‌کنیم، داده خواهد شد:

```
def backward_prop(self, softmax_output, output_label):

    l8_delta      = (output_label - softmax_output) / softmax_output.shape[0]

    l7_delta      = self.relu(self.l8, l8_delta, deriv=True)           # (batch_sz, 10)

    l6_delta, self.fc2 = self.fully_connect(self.l6, self.fc2, l7_delta, deriv=True) # (batch_sz, 200)

    l5_delta      = self.relu(self.l6, l6_delta, deriv=True)           # (batch_sz, 200)

    l4_delta, self.fc1 = self.fully_connect(self.l4, self.fc1, l5_delta, deriv=True) # (batch_sz, 16, 4, 4)

    l3_delta      = self.mean_pool(self.l3, self.pool2, l4_delta, deriv=True)   # (batch_sz, 16, 8, 8)

    l2_delta, self.conv2 = self.convolution(self.l2, self.conv2, l3_delta, deriv=True) # (batch_sz, 6, 12, 12)

    l1_delta      = self.mean_pool(self.l1, self.pool1, l2_delta, deriv=True)   # (batch_sz, 6, 24, 24)

    l0_delta, self.conv1 = self.convolution(self.l0, self.conv1, l1_delta, deriv=True) # (batch_sz, 1, 28, 28)
```

تابع convolution : یکی از مدل لایه‌هایی که در شبکه عصبی lenet استفاده می‌شود تابع convolution اولین متغیری که در این تابع استفاده شده است که برای اندازه گیری زمان اجرای این لایه از آن استفاده می‌کنیم که کاربرد اصلی آن در ادامه توضیح داده خواهد شد، متغیر N نشان دهنده تعداد شماره عکس ورودی، C نشان دهنده تعداد کanal هر عکس ورودی، W نشان دهنده عرض عکس ورودی و H نشان دهنده ارتفاع عکس ورودی است، K_NUM نشان دهنده شماره فیلتر ، K_C نشان دهنده تعداد کanal هر فیلتر، K_W نشان دهنده عرض فیلتر و K_H نشان دهنده ارتفاع فیلتر است، اگر در فاز forward_propagation باشیم یعنی deriv == false باشد آنگاه ابتدا یک آرایه به اندازه ابعاد خروجی لایه Convolution با مقدار دهی اولیه ۰ می‌سازیم و اسم آن را feature_map می‌گذاریم ، حال برای انجام عمل

روی عکس ورودی به سه حلقه for احتیاج داریم برای طی کردن مراحل و در نهایت در هر مرحله از اجرای حلقه‌ها برای محاسبه Convolution از تابع convolve2d که جلو تر در مورد آن توضیح خواهیم داد استفاده می‌کنیم، نکته مهم این تابع بخش پیاده سازی CB است که کد آن چند خط کد زیر مجموعه (if(w==28) است ، در اینجا تابع CB صدا زده می‌شود که مهم‌ترین بخش برنامه است و در ادامه به طور مفصل کاکرد این تابع را بررسی خواهیم کرد ولی به طور خلاصه این تابع اگر خطای در عکس لایه Convoltion رخ داده باشد تشخیص می‌دهد و به عکس برچسب /U می‌زند، اگر در فاز back propagation باشیم و deriv == true باشد ابتدا یک ماتریس با مقادیر صفر و با ابعاد عکس اولیه ایجاد می‌کنیم، سپس یک ماتریس با مقادیر صفر و با ابعاد فیلتر ایجاد می‌کنیم، بعد ماتریس padded_frontdelta که از روی ماتریس pad شده front_delta باشد ابتدا یک ماتریس با مقادیر صفر و با ابعاد عکس اولیه ایجاد می‌کنیم، بعد ماتریس padded_frontdelta که در مورد آن بعدتر صحبت خواهیم کرد ایجاد می‌شود، سپس ماتریس back_delta با ضرب کانولوشن padded و فیلتر ، با استفاده از ۳ حلقه for ایجاد می‌شود ، و ماتریس kernel_gradiant هم با ضرب kernel_gradient و input_map front_delta با مقادیر جدید که در نرخ آموزش ضرب می‌شود، جمع می‌شود و بروز رسانی می‌شود:

```

CB(imgId , d[num_iter_cnn] , Uth[num_iter_cnn] , input_map[imgId][cId] , featur
e_map[imgId][kId], kernal[kId,cId,:,:])#we call CB here CB's inputs:(i,d,Uth,in_image,out_im
age,filter)

#####
#####

global end_time_convolution

end_time_convolution = time.time()

return feature_map

else :

    # front->back (propagate loss)

    back_delta = np.zeros((N, C, W, H))

    kernal_gradient = np.zeros((K_NUM, K_C, K_W, K_H))

    padded_front_delta = \
        np.pad(front_delta, [(0,0), (0,0), (K_W-1, K_H-1), (K_W-1, K_H-
1)], mode='constant', constant_values=0)

    for imgId in range(N):

        for cId in range(C):

            for kId in range(K_NUM):

                back_delta[imgId][cId] += \
                    convolve2d(padded_front_delta[imgId][kId], kernal[kId,cId,:,:-1], mode='valid')

                kernal_gradient[kId][cId] += \
                    convolve2d(front_delta[imgId][kId], input_map[imgId,cId,:,:-1,:,:-1], mode='valid')


    # update weights

    kernal += self.lr * kernal_gradient

return back_delta, kernal

```

تابع mean_pool : یکی از لایه‌هایی که در شبکه lenet بارها از آن استفاده می‌شود pooling است که وظیفه کلی آن کاهش اندازه عکسی است که در مسیر شبکه عصبی در حال حرکت است تابع mean_pool همانطور که از اسمش پیداست کار کاهش اندازه ماتریس را با میانگین گرفتن از چند خانه کنار هم و نتیجه آن‌ها را به عنوان یک خانه خروجی در نظر گرفتن، انجام می‌دهد، این تابع خود از تابع block_reduce که از کتابخانه skimage.measure آورده شده ، استفاده می‌کند که در واقع همین وظیفه کاهش اندازه به وسیله میانگین گیری را انجام می‌دهد، شکل ۵ که قبل از کد تابع mean_pooling قرار گرفته به خوبی عملکرد mean_pooling را نمایش می‌دهد.



شکل ۵ : pooling با میانگین گیری

```
def mean_pool(self, input_map, pool, front_delta=None, deriv=False):
    N, C, W, H = input_map.shape
    P_W, P_H = tuple(pool)
    if deriv == False:
        feature_map = np.zeros((N, C, int(W/P_W), int(H/P_H)))
```

```

feature_map = block_reduce(input_map, tuple((1, 1, P_W, P_H)), func=np.mean)

return feature_map

else :

    # front->back (propagate loss)

    back_delta = np.zeros((N, C, W, H))

    back_delta = front_delta.repeat(P_W, axis = 2).repeat(P_H, axis = 3)

    back_delta /= (P_W * P_H)

    return back_delta

```

تابع لایه‌های lenet (fully_connected) که دو لایه انتهای شبکه را تشکیل می‌دهند به صورت کلی وظیفه کلاس بندی نهایی با تبدیل کلاس عکس به فرم one_hot را بر عهده دارند، همانطور که در تابع‌های قبلی هم دیدیم عملکرد این تابع هم در فاز forward propagation با backward propagation متفاوت است در فاز forward propagation خروجی نهایی با ضرب نقطه ای^{۳۵} ماتریس ورودی لایه که به صورت خطی در آمده در ماتریس fc در init_init مقدار دهی شده بدست می‌آید و در فاز backpropagation ابتدا ماتریس front_delta در ترانهاده fc ضرب نقطه ای می‌شود و سپس ماتریس حاصل به ابعاد ماتریس ورودی اصلی لایه در می‌آید و در نهایت ماتریس fc که همان ماتریس وزن است با ضرب نقطه ای فرم خطی شده ماتریس داده ورودی در ماتریس front_delta بدست می‌آید:

```

def fully_connect(self, input_data, fc, front_delta=None, deriv=False):

    N = input_data.shape[0]

    if deriv == False:

        output_data = np.dot(input_data.reshape(N, -1), fc)

        return output_data

    else :

        # front->back (propagate loss)

        back_delta = np.dot(front_delta, fc.T).reshape(input_data.shape)

        # update weights

```

³⁵ Dot product

```

        fc += self.lr * np.dot(input_data.reshape(N, -1).T, front_delta)

    return back_delta, fc

```

تابع `relu` که جزو توابع فعالسازی^{۳۶} است و روی خروجی توابع `fc` در شبکه `lenet` اعمال می‌شود ، اگر مقدار `x` مثبت باشد خود عدد و اگر منفی باشد صفر را بر می‌گرداند و در فاز backpropagation مقدار عدد `x` مثبت باشد باشد `front_delta` همان `back_delta` می‌شود :

```

def relu(self, x, front_delta=None, deriv=False):

    if deriv == False:

        return x * (x > 0)

    else :

        # propagate loss

        back_delta = front_delta * 1. * (x > 0)

        return back_delta

```

تابع `softmax` : `softmax` یک تابع ریاضی است که بردار اعداد را به بردار احتمالات تبدیل می‌کند، جایی که احتمالات هر مقدار متناسب با مقیاس نسبی هر مقدار در بردار است. رایج‌ترین استفاده از تابع `softmax` در یادگیری ماشین کاربردی، استفاده از آن به عنوان یک تابع فعال سازی در مدل شبکه عصبی است. به طور خاص، شبکه برای خروجی `N` مقدار، یک عدد برای هر کلاس در کار طبقه‌بندی، پیکربندی شده است، و تابع `softmax` برای عادی سازی خروجی‌ها استفاده می‌شود، و آنها را از مقادیر مجموع وزن دار به احتمالات مجموع به یک تبدیل می‌کند. هر مقدار در خروجی تابع `softmax` به عنوان احتمال عضویت برای هر کلاس تفسیر می‌شود. تابع `Softmax` اغلب در شبکه‌های عصبی استفاده می‌شود تا نتایج لایه خروجی را که نرمال نشده است به یک توزیع احتمال بر روی کلاس‌های خروجی پیش‌بینی شده نگاشت کند. کد پیاده سازی این تابع در زیر آمده، ابتدا یک لیست به نام `y` ایجاد می‌کنیم ، سپس با یک حلقه روی داده‌های ورودی به نام `x` حرکت می‌کند و در هر گام در حلقه `e` به توان t^e (که یک ردیف از `x` است) منهای بیشینه مقدار در `t` می‌کند و سپس احتمال معادل آن را در خانه‌ی متناظر در لیست `y` اضافه می‌کند :

```

def softmax(self, x):

    y = list()

```

³⁶ Activation

```

for t in x:
    e_t = np.exp(t - np.max(t))
    y.append(e_t / e_t.sum())
return np.array(y)

```

حال به معرفی توابع باقیمانده می‌پردازیم و بعد از آن برنامه را برای آموزش اجرا می‌کنیم و خروجی‌ها را بررسی می‌کنیم.

معرفی تابع Xavier : xavier_init : تلاشی برای بهبود مقداردهی اولیه ورودی‌های وزنی شبکه عصبی، به منظور جلوگیری از برخی مشکلات سنتی در یادگیری ماشین است. در اینجا، وزن‌های شبکه برای مقادیر میانی خاصی انتخاب می‌شوند که در کاربرد یادگیری ماشین مفید هستند. وزن‌ها در مقدار دهی xavier^{۳۷} با توزیع $\left(-\sqrt{\frac{6}{n_i+n_o}}, \sqrt{\frac{6}{n_i+n_o}} \right)$ محاسبه می‌شوند. تابع زیر یک ماتریس با ابعاد $c1, c2, w, h$ درست می‌کند که مقادیر درایه‌های آن بین 0 و 1 است سپس همهی خانه‌های ماتریس را منهای 1 می‌کند و در 2 ضرب می‌کند تا اعداد بین -1 و 1 شوند و در نهایت در ratio که همان رادیکال تقسیم 6 بر 1 fan_1 (تعداد ورودی لایه) بعلاوه fan_2 (تعداد خروجی از لایه) می‌کند.

پیاده سازی تابع ساده xavier به صورت زیر است :

```

def xavier_init(c1, c2, w=1, h=1, fc=False):
    fan_1 = c2 * w * h
    fan_2 = c1 * w * h
    ratio = np.sqrt(6.0 / (fan_1 + fan_2))
    params = ratio * (2 * np.random.random((c1, c2, w, h)) - 1)
    if fc == True:
        params = params.reshape(c1, c2)
    return params

```

³⁷ Xavier initialization

معرفی تابع shuffle_dataset : این تابع ابتدا تعداد کل تصاویر (N) را می‌گیرد و سپس به صورت رندوم یک جایگشت از اعداد ۰ تا N را ایجاد می‌کند، سپس ماتریس جدید x را برابر ماتریس داده‌های ورودی که خانه‌های آن به صورت جایگشتی از N جایجا شده، قرار می‌دهد و برای ماتریس برچسب عکس‌ها هم چنین می‌کند. کد این تابع بع صورت زیر است:

```
def shuffle_dataset(data, label):
    N = data.shape[0]
    index = np.random.permutation(N)
    x = data[index, :, :]; y = label[index, :]
    return x, y
```

حال به معرفی اصلی ترین تابع در پیاده سازی مدل معرفی شده در مقاله می‌پردازیم:

تابع CB (بلوک کنترلی) : این تابع که از بخش‌های مختلفی تشکیل شده اصلی ترین بخش برنامه را تشکیل می‌دهد، ورودی‌های این تابع همان ورودی هاییست که در شکل ۳ دیدیم (out_img ، in_img) به استثنای اینکه ما در اینجا img_id یعنی شماره عکسی که به این تابع می‌دهیم، d که همان پارامتر میزان کوچک شدن است، Uth که حد آستانه U است و فیلتر اصلی را به نام filter ، یه این تابع پاس می‌دهیم ; ابتدا در این تابع عکسی که هنوز خطای خود را خواهد داشت با عکس خطای خود را مقایسه کنیم، سپس دو عکس با ابعاد کوچک‌تر تولید می‌شود که فیلتر تقریبی مدل ما را اجرا کنند، میزان کوچک شدن عکس‌ها به پارامتر d که به این تابع پاس دادیم بستگی دارد، برای کوچک کردن تصاویر از همان تکنیک که در مورد تابع mean_pool توضیح دادیم استفاده می‌کنیم و تابع block_reduce را به کار می‌بریم، پس از کوچک کردن عکس‌ها با استفاده از عملیات convolution فیلترهای تقریبی را روی این دو عکس که دقیقاً کپی یکدیگر هستند اعمال می‌کنیم، در فاز بعدی باید دو عکس خروجی حاصل از عملیات convolution را با هم مقایسه کنیم، اگر این دو با هم دقیقاً برابر بودند به سراغ مرحله بعدی که برچسب گذاری عکس‌ها به صورت U یا /U است می‌رویم، نکته مهم در اینجا این است که چون ما غالباً در فاز آموزش هستیم و می‌خواهیم مقادیر و ترکیب‌های مختلف Uth و d را امتحان کنیم و بهترین آن‌ها بر اساس کمترین میزان D/U در کلاس بندی نهایی ، را انتخاب کنیم ما به دو عکسی که فیلتر تقریبی روی آن‌ها خود را خطا تزریق نمی‌کنیم تا حتماً وارد فاز بعدی بشویم.

حال که خطای تزریق نشده، حاصل اعمال دو فیلتر تقریبی یکسان است در این مرحله فرض می‌کنیم که به حاصل خروجی فیلتر اصلی است خطای تزریق شده بنابراین بعضی از بیت‌های آن را به صورت رندوم تغییر می‌دهیم، دلیل اینکه فرض می‌کنیم خطای تزریق شده هم این است که ما می‌خواهیم مقادیر و ترکیب‌های

مختلف U_{th} و d را امتحان کنیم و بهترین آن‌ها بر اساس کمترین میزان D/U در کلاس بندی نهایی، را انتخاب کنیم بنابراین باید سعی کنیم عکس‌هایی که غیر قابل استفاده هستند تولید کنیم، در گام بعدی عکس‌هایی که خطأ خورده اند را چاپ می‌کنیم تا در نهایت کاربر نهایی (در اینجا نویسنده گزارش کاربر نهاییست ولی در مقاله از یک ابزار به نام oracle استفاده کرده) بتواند تشخیص دهد که آیا واقعاً کلاس بندی U/U درست بوده؟ و در نهایت نتایج را در 4 دسته $/D/U$ ، DU ، DU/D قرار دهد ، حال نوبت برچسب گذاری عکس‌ها توسط sc است ، در این مرحله بیت به بیت عکس خروجی فیلتر اصلی (خطأ خورده) و عکس تقریبی خطأ خورده با هم مقایسه می‌شوند، اگر اختلاف دو بیت متناظر از هم بیشتر از 0.05 (نرخی که خود مقاله معرفی کرده) باشد به شمارنده counter_faulty_pixe یک واحد اضافه می‌شود، پس از انجام عمل مقایسه اگر نسبت تعداد پیکسل‌های خطأ خورده (counter_faulty_pixels) به تعداد کل پیکسل‌های یکی از دو عکس برابر است) بیشتر از $U_{th}-1$ باشد به خروجی sc برچسب U است و لایه متناظر باید مجدد اجرا گردد در غیر اینصورت نتیجه نهایی سالم است و sc برچسب U را بر می‌گرداند ، ما این برچسب‌ها را برای عکس‌های مختلف درون آرایه labels نگه داشته ایم تا در انتهای آن را چاپ کنیم و بتوانیم ارزیابی روی نتیجه نهایی را انجام دهیم:

```
def CB(img_id,d,Uth,in_image,out_image,filter):
```

```
# Plotting output images of convolution layer to compare with faulty output
```

```
plt.figure(figsize=(5,5))

plt.subplot(321)

plt.imshow(out_image.squeeze(),cmap='gray')

print('main filter output# :',img_id)

plt.axis('off')

plt.show()
```

```
#resizing image 2 times apx_img1 apx_img2
```

```
height = len(in_image)

width = len(in_image[0])

apx_img_height =int(height / d)
```

```
apx_img_width = int(width / d)

apx_img1 = np.zeros((int(width/d), int(height/d)))

apx_img1 = block_reduce(in_image, tuple((d, d)), func=np.mean)

apx_img2 = np.zeros((int(width/d), int(height/d)))

apx_img2 = block_reduce(in_image, tuple((d, d)), func=np.mean)
```

```
#implementing same conv2D on these apx_img1 apx_img2

K_W, K_H = filter.shape
```

```
apx_img1_convld = np.zeros((apx_img_width-K_W+1, apx_img_height-K_H+1)) #10 * 10
```

```
apx_img2_convld = np.zeros((apx_img_width-K_W+1, apx_img_height-K_H+1)) #10 * 10
```

```
apx_img1_convld += \
convolve2d(apx_img1, filter[:, :], mode='valid')

apx_img2_convld += \
convolve2d(apx_img2, filter[:, :], mode='valid')
```

```
#check every pixel of apx_img1 and apx_img2 equal

is_equal = np.array_equiv(apx_img1, apx_img2)
```

```
#if equal = false recompute Conv2D layer (/D)
```

```
#if equal = true go to next line
```

```

if (is_equal):
    out_img_height = len(out_image)
    out_img_width = len(out_image[0])
    #change random number =(num_chnge_bit) pixel(s) of out_image
    num_chnge_bit = random.randint(out_img_height * out_img_width)
    faulty_out_image = np.copy(out_image)
    for num_fault in range(num_chnge_bit):
        #generate two random number to inject fault in out_image
        i = random.randint(out_img_height-1)
        j = random.randint(out_img_width-1)
        rand_val = random.uniform(-1, 1)
        faulty_out_image[i,j] = rand_val

# Plotting fault injected images of convolution layer to compare with faulty output
plt.figure(figsize=(5,5))
plt.subplot(321)
plt.imshow(faulty_out_image.squeeze(),cmap='gray')
print('faulty output# :',img_id)
plt.axis('off')
plt.show()
counter_faulty_pixels = 0
for i in range(out_img_height):
    for j in range(out_img_width):
        if (abs((faulty_out_image[i,j] - out_image[i,j])) > 0.05):#the Manhattan distance of the element of output and faulty output is lower than a set threshold 0.05.

```

```

counter_faulty_pixels += 1

#define label of image

print("counter_faulty_pixels / (out_img_height * out_img_width)",counter_faulty_pixels / (o
ut_img_height * out_img_width))

if(counter_faulty_pixels / (out_img_height * out_img_width) > 1-Uth):

    label[num_iter_cnn][img_id] = '/U'

else:

    label[num_iter_cnn][img_id] = 'U'

return

```

۴.۷ مرحله ارزیابی و انتخاب U_{th} و d مناسب :

در این مرحله ما برنامه را روی حالت‌های مختلف ترکیب U_{th} و d های مختلف (جمعاً ۴ حالت) اجرا می‌کنیم، سپس برای هر یک از ۴ مرجله خروجی آرایه labels را مشاهده می‌کنیم و با مقایسه برچسب‌های /U و U که در این آرایه قرار گرفته و عکس‌هایی که چاپ شده اند نتایج را در ۴ گروه /D/U ، DU/D ، D/U و DU دسته بندی می‌کنیم ، و در نهایت ترکیبی از U_{th} و d که کمترین میزان /D/U را داشته باشد برای مدل اصلی انتخاب می‌شود، توجه داشته باشید ما در اینجا cb را برای ۱ لایه قرار دادیم تا از پیچیدگی زیاد و بی مورد پرهیز کنیم اگر بنا باشد برای همه لایه‌ها cb را قرار دهیم مراحل گفته شده دقیقاً مانند قبل طی می‌شود ولی تنها دو تفاوت وجود دارد، ۱ - تابع cb در تمام لایه‌هایی که می‌خواهیم برای آن cb قرار دهیم صداد زده می‌شود، ۲ - در نتیجه گیری نهایی به ازای هر ترکیبی از U_{th} و d های مختلف که در نظر می‌گیریم، برای هر لایه یک آرایه labels تولید می‌شود که ما از روی آن لایه و عکس‌های خروجی چاپ شده می‌توانیم تعداد /D/U را بدست بیاوریم ، حالا بین تعداد /D/U در تمام لایه‌ها میانگین می‌گیریم و انتخاب ترکیب نهایی U_{th} و d بر اساس این میانگین‌ها است.

ما در مرحله ارزیابی دو مقدار ۰.۴۵ و ۰.۸۵ را برای U_{th} و دو مقدار ۲ و ۴ را برای d در نظر گرفتیم که ترکیب این‌ها با هم ۴ حالت را می‌سازد که می‌توانید در کد زیر آرایه‌هایی که تعریف شده اند را ببینید:

$$d = [2, 4, 4, 2]$$


$$U_{th} = [0.85, 0.45, 0.85, 0.45]$$

در مرحله i از ارزیابی خانه i ام آرایه d به عنوان مقدار d و خانه i ام آرایه Uth به عنوان Uth انتخاب می‌شوند و به تابع cb پاس داده می‌شوند ، برای کاهش پیچیدگی و سهولت بررسی ما الگوریتم را روی ۱۰ داده آموزشی از پایگاه داده mnist اجرا کرده ایم ، بخشی از خروجی برنامه به صورت زیر است (برای پرهیز از حشو و طولانی شدن گزارش تمام خروجی را در این گزارش نیاورده ایم و خروجی برنامه را ضمیمه فایل ارسالی کرده ایم):

main filter output# : 0



faulty output# : 0




counter_faulty_pixels / (out_img_height * out_img_width) 0.4149305555555556

main filter output# : 1



faulty output# : 1




counter_faulty_pixels / (out_img_height * out_img_width) 0.3298611111111111

main filter output# : 2




faulty output# : 2




counter_faulty_pixels / (out_img_height * out_img_width) 0.5746527777777778

main filter output# : 3




faulty output# : 3




counter_faulty_pixels / (out_img_height * out_img_width) 0.4392361111111111

main filter output# : 4




faulty output# : 4




counter_faulty_pixels / (out_img_height * out_img_width) 0.2065972222222222

main filter output# : 5




faulty output# : 5




counter_faulty_pixels / (out_img_height * out_img_width) 0.46875

main filter output# : 6




faulty output# : 6




counter_faulty_pixels / (out_img_height * out_img_width) 0.005208333333333333

main filter output# : 7




faulty output# : 7




counter_faulty_pixels / (out_img_height * out_img_width) 0.517361111111112

main filter output# : 8




faulty output# : 8




counter_faulty_pixels / (out_img_height * out_img_width) 0.390625

main filter output# : 9



faulty output# : 9



counter_faulty_pixels / (out_img_height * out_img_width) 0.2847222222222222

label[num_iter_cnn][] : ['/U', '/U', '/U', '/U', '/U', '/U', 'U', '/U', '/U', '/U']

total execution time of double execution of CNN : 1.8011231422424316 (seconds)

start_time_conv1 : 1675578081.321698

end_time_convolution : 1675578081.2724423

execution time of program with approximate base technique : 0.8513059616088867 (seconds)

همانطور که می‌بینید فرضاً برای حالت اول که $U_{th} = 0.85$ و $d = 2$ است آرایه labels به صورت زیر می‌باشد:

label[1][:] : ['/U', '/U', '/U', '/U', '/U', '/U', 'U', '/U', '/U', '/U']

با بررسی عکس‌های چاپ شده می‌بینیم مقدار U/D برای این حالت برابر صفر است، برای سایر حالات نتیجه به صورت زیر است:

حالت دوم ($d = 4$ و $U_{th} = 0.45$) : مقدار D/U برابر ۵ است.

حالت سوم ($d = 4$ و $U_{th} = 0.85$) : مقدار D/U برابر ۰ است.

حالت چهارم ($d = 2$ و $U_{th} = 0.45$) : مقدار D/U برابر ۸ است.


از نتایجی که بدست آمده مشاهده می‌کنیم حالت سوم و اول کمترین U/D را دارند و با توجه به زمانی که این دو اجرا شده اند (زمان اجرا معیار دوم مقاله برای انتخاب از بین حالات است)، زمان اجرای حالت سوم برابر ۰.۹۰۸۷۷۸۹۰۵۸۶۸۵۳۰۳ و زمان اجرای حالت اول برابر ۰.۸۵۱۳۰۵۹۶۱۶۰۸۸۸۶۷ دارد، که در این اجرا حالت اول عملکرد بهتری داشته.

(۵) نتیجه‌گیری:


از بررسی نتایج به دست آمده از اجرای مدل معرفی شده می‌توانیم ببینیم اگر می‌خواستیم از تکنیک DWC استفاده کنیم و کل شبکه عصبی را در هر لایه دو مرتبه اجرا کنیم تا خطا را متوجه شویم زمان اجرای برنامه ۲ برابر می‌شود، اما در اینجا با توجه به اینکه در هر لایه مقایسه روى داده‌های تقریبی انجام می‌شود (با اندازه کوچک‌تر از اندازه داده اصلی) حجم محاسبات برای تشخیص خطا تا حد زیادی کاهش می‌یابد و همچنین فقط به ازای داده‌هایی که U/D هستند مجبوریم فقط آن لایه ای که خطا خورده را دوباره اجرا کنیم در نتیجه به طور منطقی قطعاً زمان اجرا تا حد بسیار زیادی پایین می‌آید، همانطور که در پیاده سازی این تکنیک هم می‌بینیم زمان اجرا برای پیاده سازی که ما انجام دادیم نسبت به روش DWC تقریباً نصف است، که این نشان دهنده

کارایی بالای مدل پیشنهادی مقاله است، همچنین دقت هم در این مدل بسیار بالاست، چرا که در نتایج بدست آمده در پیاده سازی هم دیدیم که مقدار D/U منفی های اشتباه صفر بوده و خطایی که خود مقاله اعلام کرده که در پیاده سازی در ابعاد بالاتر به آن رسیده تنها ۴ درصد است که این نکته مثبت دیگر این مدل است.

در نتایج بهدست آمده در ۴ حالت پیاده سازی شده توسط نویسنده گزارش همان طور که انتظار می رفت با افزایش U_{th} دقت افزایش می یابد (به این معنی که تعداد D/U ها کاهش می یابد) و با کاهش d زمان اجرا افزایش می یابد، در این اجرا چون تعداد خطا های تزریق شده به صورت رندوم هستند علت اینکه زمان اجرا $d = 4$ از $d = 2$ بیشتر شده این است که تعداد خطا هایی که تزریق شده در $d = 4$ بیشتر بوده و حلقه for مربوط به تزریق خطا بیشتر اجرا شده، شکل ۶ نمودار ۴ حالت بهدست آمده برای U_{th} و d ها را نشان می دهد که محور x آن نشان دهنده مقدار D/U و محور y آن نشان دهنده زمان اجراست، همان طور که می بینید نتیجه بهدست آمده با شکل ۷ که از مقاله اصلی گرفته شده تطابق منطقی ای دارد.



شکل ۶ : نمودار نتیج بدست آمده برای نمودار ۴ حالت بهدست آمده برای U_{th} و d های مختلف



شکل ۷ : نمونه ای از پیکربندی های مختلف ارائه شده توسط مقاله.

۶) فهرست مراجع

- [1] J. Andersson, M. Hjorth, F. Johansson, and S. Habinc, “LEON Processor Devices for Space Missions: First 20 Years of LEON in Space,” in Int. Conf. Space Mission Challenges for Inform. Tech., 2017, pp. 136–141
- [2] M. Fayyaz and T. Vladimirova, “Fault-tolerant distributed approach to satellite on-board computer design,” in Aerospace Conf., 2014, pp. 1–12.
- [3] M. Biasielli, C. Bolchini, L. Cassano, E. Koyuncu, and A. Miele, “A Neural Network Based Fault Management Scheme for Reliable Image Processing,” IEEE Trans. Computers, vol. 69, no. 5, pp. 764–776, 2020.

پایان